



DATOS GENERALES DEL ESTUDIANTE

Nombre Estudiante	Carlos Alex Macias Perdomo
Programa Académico	Maestría en IA y ciencia de datos
Cédula	94488915
Código Estudiantil	22500208
Correo	carlos_ale.macias@uao.edu.co

DATOS GENERALES DEL DIRECTOR

Nombre Director	Maritza Correa Valencia Ingeniera Industrial - Doctora en ciencias de la computación e inteligencia artificial
Correo	mcorrea@uao.edu.co

DATOS DEL ANTEPROYECTO

TÍTULO DEL PROYECTO
PREDICCIÓN INTELIGENTE DE LA DEMANDA DE PASAJEROS MEDIANTE TÉCNICAS DE APRENDIZAJE AUTOMÁTICO PARA APOYAR LA

**OPTIMIZACIÓN DEL DESPACHO VEHICULAR EN LA EMPRESA
MONTEBELLO.**


PALABRAS CLAVES/KEY WORDS

**Predicción de demanda de pasajeros, Aprendizaje automático,
Inteligencia artificial, Transporte público urbano**

RESUMEN

El presente proyecto propone la implementación de un modelo de inteligencia artificial orientado a predecir la demanda y apoyar la programación de despachos de vehículos en sistemas de transporte público urbano. Se toma como caso de estudio la empresa Montebello, utilizando datos históricos provenientes de registros de despacho, sistemas de posicionamiento global (GPS) y conteo automático de pasajeros (APC). La metodología contempla un proceso de extracción, transformación y carga (ETL), seguido de un análisis descriptivo que caracterice patrones de frecuencia, demanda y comportamiento operacional. Posteriormente, se implementarán y evaluarán modelos predictivos basados en diferentes algoritmos, con el fin de determinar la arquitectura con mejor desempeño en la estimación de la demanda de pasajeros y las frecuencias de despacho. Los resultados del estudio permitirán proponer un esquema de predicción aplicable en la planificación operativa de empresas de transporte público y establecer las bases para futuras aplicaciones de inteligencia artificial en la gestión del servicio.

**PREDICCIÓN INTELIGENTE DE LA DEMANDA DE PASAJEROS
MEDIANTE TÉCNICAS DE APRENDIZAJE AUTOMÁTICO PARA
APOYAR LA OPTIMIZACIÓN DEL DESPACHO VEHICULAR EN LA
EMPRESA MONTEBELLO**



**CARLOS ALEX MACÍAS PERDOMO
CÓDIGO 22500208**

**UNIVERSIDAD AUTÓNOMA DE OCCIDENTE
FACULTAD DE INGENIERÍA Y CIENCIAS BÁSICAS
PROGRAMA MAESTRÍA EN IA Y CIENCIA DE DATOS
SANTIAGO DE CALI
2025**

TABLA DE CONTENIDO

INTRODUCCIÓN	6
1. PLANTEAMIENTO DEL PROBLEMA	8
1.1. Contexto general.....	8
1.2. Descripción del problema central	8
1.3. Evidencia y respaldo teórico	9
1.4. Delimitación del problema.....	10
1.5. Pregunta de Investigación.....	10
2. OBJETIVOS	11
2.1. Objetivo General	11
2.2. Objetivos Específicos.....	11
3. JUSTIFICACIÓN Y ALCANCE	11
3.1. Justificación teórica.....	11
3.2. Justificación metodológica	12
3.3. Justificación práctica	13
3.4. Alcance	14
4. ANTECEDENTES Y ESTADO DEL ARTE	16
5. MARCO TEÓRICO.....	18
6. DISEÑO METODOLÓGICO Y EXPERIMENTAL	22
6.1. Cronograma de actividades.	26
6.2. Resultados esperados.	27
7. RECURSOS Y ASPECTOS ECONÓMICOS.....	28

8. REFERENCIAS.....	30
---------------------	----

INTRODUCCIÓN

La movilidad urbana es el pilar fundamental en el desarrollo sostenible de las ciudades contemporáneas. El crecimiento de la población, la expansión del territorio y la diversificación de las actividades económicas han incrementado la necesidad de contar con sistemas de transporte público más eficientes. La gestión operativa de las empresas de transporte enfrenta el reto de equilibrar la oferta y demanda de pasajeros, procurando la optimización de los recursos, la reducción de los tiempos de espera y la mejora de la calidad del servicio percibida por los usuarios (Box & Jenkins, 2015; Turner & Wright, 2020).

Durante las últimas décadas, los avances tecnológicos y la digitalización de los procesos han permitido a las empresas de transporte registrar grandes cantidades de datos de sistemas automáticos de pasajeros (APC), dispositivos de ubicación satelital (GPS) y plataformas transaccionales. Estos datos que se utilizan históricamente para el control son los insumos para la toma de decisiones basadas en evidencias, en este caso la predicción de la demanda de pasajeros, se consolida como una herramienta esencial para anticipar los flujos de movilidad y con ello ajustar los despachos de vehículos de acuerdo con las condiciones reales de la operación (Litman, 2022; Turban, Sharda, & Delen, 2021).

En el contexto colombiano y en especial la ciudad de Cali, la planeación del transporte público enfrenta limitaciones derivadas de la falta de integración tecnológica, la variabilidad de la demanda y la ausencia de modelos predictivos operativos. La empresa Montebello, prestadora del servicio de transporte público colectivo, es un caso representativo de esta situación. Su esquema actual de despacho de buses se apoya en la experiencia del personal operativo basados en criterios empíricos, que, aunque funcionales, no permiten anticipar adecuadamente las variaciones diarias en la demanda de pasajeros. Lo que provoca sobreoferta o

escasez de buses, afectando la regularidad del servicio, la eficiencia en la utilización de la flota y satisfacción del usuario.

Frente a este problema, el presente trabajo de grado propone la implementación de modelos de predicción de la demanda de pasajeros aplicado al contexto operativo de la empresa Montebello, con el propósito de identificar el mejor modelo que adapte a las condiciones reales y proporcione información útil para apoyar la optimización del despacho vehicular.

La metodología propuesta se estructura en cuatro etapas principales.

- Recopilación y análisis de datos históricos de la operación de Montebello, identificando las variables más relevantes para el comportamiento de la demanda de pasajeros.
- El diseño de la arquitectura del sistema de predicción, definiendo el flujo de procesamiento y los criterios de evaluación del desempeño.
- Implementación y validación de diferentes modelos predictivos, empleando técnicas de análisis comparativos para determinar el modelo más preciso y estable.
- Interpretación de resultados, que se orienten a recomendaciones en la programación del despacho vehicular, fortaleciendo la toma de decisiones operativas fundamentada en datos.

1. PLANTEAMIENTO DEL PROBLEMA

1.1. Contexto general

El transporte público urbano constituye un componente esencial para la movilidad sostenible, la equidad social y la eficiencia energética de las ciudades modernas. Su adecuada planificación depende de la capacidad de anticipar la demanda de pasajeros y asignación de recursos operativos en tiempo real. No obstante, en muchos sistemas de transporte, en especial aquellos con estructura semiformalizada o modelos de flota afiliada, la gestión operativa continúa dependiendo de las prácticas manuales, experiencia empírica y criterios subjetivos. Empresa Transportes Montebello es una empresa de transporte público urbano con sede en Cali, que opera bajo un modelo de afiliación en donde los vehículos pertenecen a los propietarios particulares y la empresa administra la operación. Este modelo, aunque económicamente viable, genera una descentralización operativa que dificulta la planificación anticipada de despacho vehicular, al depender de la disponibilidad diaria de buses y conductores, además del estado mecánico de los buses y la rotación del personal.

1.2. Descripción del problema central

El proceso de despacho en Montebello es manual y empírico. Un funcionario (despachador) asigna rutas y horarios basándose en reglas de la empresa, experiencia, la disponibilidad del momento y criterios informales. Este procedimiento, aunque funcional, no garantiza la regularidad en los intervalos de despacho (headways), ni una distribución equitativa de los turnos entre los vehículos afiliados.

Como consecuencia se presentan tres efectos operativos críticos:

- Irregularidad en la frecuencia de despacho. Con buses que salen a intervalos variables, genera tiempos de espera inciertos para los usuarios.
- Inequidad entre conductores. Algunos conductores obtienen horarios o rutas más favorables mediante prácticas informales o favoritismos.
- Competencia desleal (guerra del centavo). Algunos conductores alteran sus horarios o trayectos para captar más pasajeros, afectando el orden y la calidad del servicio.

1.3. Evidencia y respaldo teórico

La literatura demuestra que los modelos basados en inteligencia artificial (IA) y aprendizaje profundo (Deep Learning) han alcanzado resultados sobresalientes en la predicción del flujo de pasajeros, especialmente en contextos urbanos formales y centralizados.

Diversas investigaciones, como la de (Yu, Yin, & Zhu, 2018) con el modelo spatio-temporal graph convolutional network (STGCN), (Han, y otros, 2019) con el hybrid optimized long short-term memory (LSTM) y (Matseliukh, Lytvyn, & Bublyk, 2025), así como la propuesta de (He, Li, Zhu, & Tsui, 2022) con la multi-graph convolutional-recurrent neural network, confirman que las redes neuronales recurrentes tales como recurrent neural network (RNN), LSTM, gated recurrent unit (GRU) y convolucionales (CNN) y graph convolutional network (GCN) logran alta precisión en la predicción de demanda de pasajeros a corto plazo.

Asimismo, la revisión sistemática de (Adjei Boateng, Adams, & Akowuah, 2023), muestra que la mayoría de los modelos de machine learning (ML) actuales en contextos urbanos con datos completos y control operativo, dejando sin resolver la adaptación a sistemas descentralizados como Montebello.

En consecuencia, aunque existen avances técnicos robustos, persiste una brecha tecnológica estructural presente en sistemas semiformalizados.

1.4. Delimitación del problema

- Ámbito geográfico. Empresa de transportes Montebello, Cali, Colombia.
- Ámbito temporal. Periodo de análisis 2022-2025, con datos históricos de pasajeros, despachos y GPS.
- Ámbito temático. Aplicación de modelos de aprendizaje automático para la predicción de demanda de pasajeros a corto plazo, integrando variables operativas (disponibilidad de vehículos, horarios, condiciones climáticas).
- Alcance funcional. El modelo no reemplaza la decisión del despachador humano, sino que genera sugerencias inteligentes de despacho basadas en predicciones de demanda, contribuyendo a la toma de decisiones informada.

1.5. Pregunta de Investigación

¿Cómo implementar un modelo de inteligencia artificial para la predicción de la demanda de pasajeros que, aplicado en un sistema básico de apoyo al despacho vehicular, permita mejorar la planificación operativa en la empresa de transporte Montebello?

2. OBJETIVOS

2.1. Objetivo General

Mejorar la eficiencia operativa por medio de la implementación de un modelo de aprendizaje automático para la predicción de la demanda de pasajeros.

2.2. Objetivos Específicos

- Identificar los patrones temporales y operativos de la demanda de pasajeros a partir del análisis de los registros históricos de la empresa Montebello.
- Diseñar la arquitectura del modelo predictivo y el flujo de procesamiento de datos que soporte la estimación de la demanda.
- Implementar el modelo de aprendizaje automático con mejor desempeño para la predicción de la demanda de pasajeros.
- Evaluar la precisión y aplicabilidad del modelo implementado como apoyo de la programación y despacho vehicular.

3. JUSTIFICACIÓN Y ALCANCE

3.1. Justificación teórica

El transporte público urbano constituye un componente esencial de la movilidad sostenible y de la calidad de vida en las ciudades. En este contexto, la capacidad para anticipar la demanda de pasajeros se ha convertido en un factor crítico para garantizar la eficiencia operativa y la equidad en la asignación de recursos.

La revisión de la literatura reciente evidencia un avance significativo en el uso de modelos de IA para la predicción de flujos de pasajeros, particularmente mediante RNN y sus principales variantes, como las redes LSTM y GRU. Estas arquitecturas

han demostrado gran capacidad para modelar dependencias temporales de series de tiempo. De igual manera, los modelos híbridos que combinan redes convolucionales y recurrentes (CNN-LSTM), junto con algoritmos de aprendizaje automático como extreme gradient boosting (XGBoost) o el modelo de pronóstico basado en descomposición aditiva desarrollado por Meta (Prophet), amplían las posibilidades de capturar tanto las relaciones espaciales como las temporales.

No obstante, la mayoría de estos estudios se enfocan en sistemas de transporte formalizados y centralizados como, por ejemplo, redes de metro o buses de tránsito rápido (BRT), con estructuras operativas altamente estables.

En contraste, el caso de Transportes Montebello, una empresa con un modelo de flota afiliada y operación descentralizada presenta un entorno menos predecible y más variable.

Esta situación configura una brecha teórica y aplicada en la literatura, no existen suficientes investigaciones que adapten los modelos de predicción de demanda a contextos reales, heterogéneos y dinámicos como los del transporte público colombiano.

Por ello, el presente proyecto aporta evidencia empírica y metodológica sobre la aplicabilidad de técnicas avanzadas de IA en escenarios operativos reales, contribuyendo a ampliar el conocimiento existente sobre predicción de demanda en sistemas semiformalizados y su posible integración con sistemas de apoyo a la decisión.

3.2. Justificación metodológica

Desde el punto de vista metodológico, el proyecto se fundamenta en el paradigma aplicado de la inteligencia artificial y la ciencia de datos, utilizando técnicas de aprendizaje supervisado para modelar la relación entre variables temporales, operativas y espaciales que influyen en la demanda de pasajeros.

La propuesta integra un flujo de procesamiento de datos mediante ETL, la implementación comparativa de modelos de aprendizaje automático y profundo, y la evaluación de desempeño bajo distintos escenarios operativos (horarios pico y valle, días laborales, festivos, condiciones climáticas, etc.).

Esta aproximación permite no solo determinar el modelo más preciso, sino también evaluar su estabilidad, generalización y robustez, atributos esenciales para la adopción práctica de soluciones basadas en IA en entornos reales.

El enfoque metodológico incorpora además un módulo básico de apoyo al despacho vehicular, construido sobre reglas heurísticas simples derivadas de las predicciones del modelo, que ejemplifica cómo la IA puede integrarse de manera gradual a la toma de decisiones operativas sin sustituir al factor humano.

De esta forma, la metodología combina rigor científico y aplicabilidad técnica, aportando una ruta reproducible y escalable para futuros desarrollos en empresas de transporte similares.

3.3. Justificación práctica

Desde la perspectiva práctica, el proyecto responde a una necesidad concreta de la empresa Montebello con el mejoramiento de la eficiencia y regularidad del despacho vehicular mediante el uso de información predictiva.

El actual proceso de asignación de rutas se realiza manualmente, basado en experiencia empírica y disponibilidad inmediata de vehículos, lo cual genera ineficiencias, tiempos de espera irregulares y desigualdad en la distribución de turnos entre conductores.

Al implementar un modelo de predicción de demanda de pasajeros, la empresa contará con información anticipada y cuantitativa sobre los niveles esperados de ocupación, lo que permitirá planificar con mayor precisión los despachos, optimizar la utilización de la flota y reducir la variabilidad en la frecuencia de salidas (headway).

El desarrollo del módulo de apoyo al despacho aportará un beneficio institucional y social ofreciendo una herramienta transparente que apoyará la toma de decisiones del despachador, contribuyendo a mejorar la equidad entre conductores, incrementar la satisfacción de los usuarios y favorecer la movilidad sostenible. En términos económicos, la disponibilidad de predicciones confiables puede traducirse en mejor aprovechamiento del parque automotor, reducción de costos operativos y mayor rentabilidad por optimización de recursos.

Finalmente, el proyecto aportará al fortalecimiento de la capacidad analítica de la empresa y servirá como caso de referencia para la aplicación práctica de técnicas de inteligencia artificial en el sector transporte, potenciando la transferencia tecnológica y la toma de decisiones basadas en datos.

3.4. Alcance

El proyecto abarca el desarrollo completo del proceso de predicción de demanda de pasajeros y la implementación de un módulo básico de apoyo al despacho vehicular, conforme a los siguientes límites:

3.4.1 Alcance técnico

Se desarrollará una arquitectura de datos y un pipeline ETL que integre la información operativa de Montebello (fecha, hora, ruta, ocupación, clima, día de la semana, tipo de jornada).

Se implementarán y compararán modelos de aprendizaje automático y profundo (ARIMA, Prophet, XGBoost, LSTM, GRU), seleccionando el más adecuado según métricas de desempeño como lo son mean absolute error (MAE), root mean squared error (RMSE) y mean absolute percentage error (MAPE).

El sistema incluirá un módulo heurístico de recomendaciones que, a partir de las predicciones, sugiera ajustes o refuerzos de despachos según la demanda estimada.

3.4.2. Alcance operativo

El sistema se implementará y evaluará mediante una prueba piloto en la empresa Montebello, utilizando datos históricos y operativos para validar su desempeño en distintos escenarios de operación.

La implementación corresponderá a la selección, entrenamiento y validación del modelo de predicción de demanda de pasajeros a corto plazo, identificando el de mejor métricas (MAE, RMSE, y MAPE).

Los resultados obtenidos de este modelo serán el insumo de entrada para un módulo básico de apoyo al despacho vehicular, el cual funcionará como una herramienta de recomendación que sugiere ajustes operativos sin reemplazar las funciones del despachador.

3.4.3. Alcance institucional

El proyecto se desarrollará en colaboración con la empresa Montebello, que proporcionará los datos operativos necesarios y apoyará la comprensión del contexto de la operación. La responsabilidad de implementar, analizar y validar el

modelo predictivo recaerá en el autor del trabajo, quien ejecutará estas actividades con fines académicos y de experimentación aplicada.

3.4.4. Límites del proyecto

No se contempla la automatización completa del proceso de despacho ni la integración con sistemas de control vehicular en tiempo real. El alcance se limita a la generación de información analítica y recomendaciones operativas, basadas en modelos predictivos, con el fin de demostrar su utilidad y factibilidad.

4. ANTECEDENTES Y ESTADO DEL ARTE

- Panorama internacional

En los últimos años, los avances en el uso de modelos ML e IA para la predicción de la demanda de pasajeros en transporte público han sido significativos. Los modelos estadísticos tradicionales, como ARIMA y Prophet, continúan siendo referentes por su interpretabilidad y desempeño en contextos con datos estructurados. (Chuwang & Chen, 2022) demostraron que Prophet superó a SARIMA en la predicción diaria de pasajeros en sistemas ferroviarios urbanos, al capturar mejor la estacionalidad múltiple y los efectos de los días festivos (Chuwang & Chen, 2022). En paralelo, métodos de ML como XGBoost han mostrado un rendimiento competitivo frente a redes neuronales profundas, destacando su estabilidad y baja varianza en escenarios operativos reales (Adjei Boateng, Adams, & Akowuah, 2023) (Han, y otros, 2019). Diversos estudios entre 2020 y 2025 han explorado arquitecturas profundas, híbridas y espaciotemporales que superan a los modelos tradicionales de series temporales.

(Rocco, 2024) presentó una revisión sobre el uso de ML en transporte, destacando la transición hacia modelos espaciotemporales e híbridos que incorporan variables contextuales. (Luo, y otros, 2021) desarrollaron el modelo multitask deep learning for service-level passenger flow prediction (MDL-SPFP), basado en aprendizaje profundo multitarea con atención y convoluciones, logrando mejoras frente a ARIMA y SVR. (Hoppe, Müller, & Schäfer, 2023), fusionaron predicciones de corto plazo con datos de ocupación en tiempo real, reduciendo errores en escenarios operativos reales. (Yazıcıoğlu & Erdem, 2025) evaluaron modelos LSTM multivariados en sistemas de transporte mixtos, confirmando su estabilidad predictiva ante diferentes condiciones horarias y climáticas.

- Aportes nacionales y regionales (Colombia y América Latina).

En el ámbito latinoamericano, destacan investigaciones aplicadas al contexto colombiano. (Wang & Shalaby, 2024) integró graph neural network (GNN) y GRU para predecir flujos de pasajeros en el sistema BRT de Bogotá, demostrando mejoras en precisión y eficiencia. (Rodríguez-Valencia, 2023) documentó la transformación del sistema de buses de Bogotá con el sistema integrado de transporte público (SITP), aportando contexto sobre la necesidad de regularidad operativa. Otros estudios, como el de (Martínez, Pérez, & Rojas, 2024), incorporaron análisis de escenarios para la planificación táctica del despacho vehicular, mostrando el potencial del aprendizaje automático para mejorar la toma de decisiones operativas.

- Síntesis críticas y brechas encontradas.

La literatura coincide en que los modelos de aprendizaje profundo (LSTM, GRU, CNN-LSTM) y los híbridos espaciotemporales ofrecen mejor desempeño que los enfoques tradicionales. Sin embargo, la mayoría de los estudios se centran en sistemas formales con control centralizado, dejando un vacío de evidencia sobre su aplicabilidad en contextos descentralizados, como el de Montebello. Asimismo, pocos trabajos han evaluado la

estabilidad de los modelos bajo diferentes escenarios operativos (pico, valle, días festivos o condiciones climáticas), aspecto que este proyecto abordará para incrementar la validez externa de los resultados.

5. MARCO TEÓRICO

El presente marco teórico expone los fundamentos conceptuales, técnicos y metodológicos que sustentan el desarrollo de un sistema de predicción de la demanda de pasajeros mediante IA, aplicado al caso de la empresa Transportes Montebello.

En él se abordan los conceptos esenciales relacionados con el transporte público y su gestión operativa, los fundamentos de la ciencia de datos y el aprendizaje automático, así como los enfoques teóricos de predicción de demanda y decision support system (DSS).

El propósito es integrar los referentes académicos que explican cómo la IA puede transformar la planificación operativa en sistemas de transporte urbano, particularmente en contextos descentralizados como el de Montebello.

Transporte público y eficiencia operativa.

El transporte público urbano es un servicio fundamental para la movilidad sostenible, la inclusión social y el desarrollo económico (Litman, 2022). Su eficiencia depende de la sincronización entre la oferta (vehículos, frecuencias y horarios) y la demanda real de pasajeros (Turner & Wright, 2020).

Cuando la programación y el despacho se realizan de manera empírica, como ocurre en empresas con flotas afiliadas, se generan problemas de ineficiencia, inequidad y descoordinación, conocidos en la literatura como fenómenos de headway irregularity o bus bunching (Chen, Liu, & Zhu, 2020).

La eficiencia operativa en transporte se mide por indicadores como headway, la regularidad del servicio y el aprovechamiento de la flota (Ceder, 2016). Estos indicadores son sensibles a la precisión con la que se anticipa la demanda de pasajeros, lo que justifica el uso de modelos predictivos como herramienta estratégica para la gestión táctica del transporte público (Chuwang & Chen, 2022).

Predicción de demanda de pasajeros.

La predicción de demanda consiste en estimar, para un horizonte temporal futuro, del número de pasajeros que utilizarán un servicio de transporte, en función de variables históricas y contextuales (Zhao, Wang, & Li, 2021).

Su objetivo es ajustar la oferta operativa (buses, horarios, frecuencias) a las condiciones reales de movilidad, minimizando tiempos de espera y optimizando recursos.

En sistemas avanzados de transporte (BRT, metro, ferrocarril), esta predicción se usa para la planificación dinámica de flota, el control de aforo y la optimización de rutas (Yu, Yin, & Zhu, 2018).

Sin embargo, en contextos menos formalizados, como Montebello, la predicción tiene un rol más táctico, generar información anticipada para apoyar la toma de decisiones humanas en el despacho.

Enfoques tradicionales.

Los métodos clásicos de predicción, basados en modelos estadísticos de series temporales, incluyen ARIMA, SARIMA y VAR (Box & Jenkins, 2015).

Estos enfoques asumen linealidad y estacionariedad, lo que limita su capacidad para capturar comportamientos no lineales o dependencias entre múltiples variables (Zhang, 2020).

Aunque son útiles como referencia o modelo base (baseline), su desempeño decrece cuando la demanda depende de factores externos cambiantes (clima, día de la semana, eventos, condiciones operativas).

Aprendizaje automático y profundo.

Los modelos de ML y deep learning (DL), permiten modelar relaciones no lineales y dinámicas complejas. Estos modelos aprenden a partir de datos históricos y permiten generar predicciones de corto, mediano o largo plazo, según la naturaleza del problema y la granularidad temporal de los datos (por minuto, hora, día, semana).

En la literatura reciente destacan los modelos de aprendizaje automático resumidos en la tabla 1:

Tabla 1. Tipos de modelo de aprendizaje automático aplicados a la predicción de la demanda.

Tipo de modelo	Ejemplo / Referencia	Características principales
Regresión avanzada (ML)	XGBoost, Random Forest	Alta precisión con bajo costo computacional; capta interacciones no lineales.
Modelos neuronales recurrentes (RNN, LSTM, GRU)	Luo et al. (2021), Yazıcıoğlu & Erdem (2025)	Capturan dependencias temporales y patrones secuenciales.
Modelos híbridos (CNN-LSTM, GNN-GRU)	DST-TransitNet (2024)	Integran relaciones espaciales y temporales; alto rendimiento en transporte urbano.
Modelos con variables exógenas	Ouyang, Lv, Ma & Li (2020)	Mejoran la precisión al incluir clima, calendario o eventos especiales.

Fuente: elaboración propia.

Sistemas de apoyo a la decisión.

Los DSS se definen como plataformas que combinan datos, modelos y conocimiento experto para asistir a los tomadores de decisiones en problemas complejos (Turban, Sharda, & Delen, 2021).

Un DSS moderno integra tres componentes principales:

- Subsistema de datos, que recopila y estructura información interna y externa.
- Subsistema de modelos, que aplica técnicas analíticas, estadísticas o de IA para generar conocimiento.

- Subsistema de interfaz, que permite al usuario interactuar con los resultados para apoyar su decisión.

En el contexto del transporte público, los DSS se aplican para optimizar el despacho, la asignación de flota y la programación horaria (Ceder, 2016).

El presente proyecto se enmarca en esta concepción, implementa un modelo predictivo de demanda (subsistema de modelos), alimentado por datos históricos operativos (subsistema de datos), y genera sugerencias simples de despacho (subsistema de interfaz), representando un DSS básico orientado a la decisión táctica.

Inteligencia artificial aplicada al transporte.

La aplicación de IA en transporte público se centra en la automatización y mejora de la toma de decisiones operativas.

Según el IEEE Transactions on Intelligent Transportation Systems (2022), los principales ámbitos de aplicación incluyen:

- Predicción de demanda y ocupación.
- Control adaptativo de semáforos y tráfico.
- Optimización de rutas y asignación de flota.
- Análisis de comportamiento del pasajero.

El uso de IA en predicción de demanda combina varias etapas: preprocesamiento, entrenamiento, evaluación y despliegue. Cada una requiere conocimiento interdisciplinar de ingeniería de datos, estadística y aprendizaje de máquinas.

Escenarios operativos y robustez del modelo.

El concepto (Adjei Boateng, Adams, & Akowuah, 2023) de escenario operativo hace referencia a las condiciones bajo las cuales se evalúa el desempeño del modelo:

- Hora del día (pico/valle).
- Tipo de día (laboral, festivo, fin de semana).

- Clima (seco/lluvioso).
- Ruta o zona de operación.

Analizar la respuesta del modelo bajo distintos escenarios permite evaluar su robustez, generalización y estabilidad, dimensiones esenciales para una aplicación confiable en sistemas de transporte reales (Han, y otros, 2019).

Como conclusión, el marco teórico expuesto demuestra que la predicción de demanda mediante IA constituye un campo consolidado en la literatura internacional, pero aún presenta brechas de aplicación en entornos de operación descentralizada.

La integración de modelos predictivos con sistemas de apoyo a la decisión ofrece una oportunidad para profesionalizar la gestión operativa en empresas como Montebello, permitiendo decisiones basadas en datos en lugar de criterios empíricos.

6. DISEÑO METODOLÓGICO Y EXPERIMENTAL

El diseño metodológico establece la forma de obtención, procesamiento y análisis de la información que permitirá dar respuesta a la pregunta de investigación:

¿Cómo implementar un modelo de inteligencia artificial para la predicción de la demanda de pasajeros que, aplicado en un sistema básico de apoyo al despacho vehicular, permita mejorar la planificación operativa en la empresa Montebello?

El procesamiento, modelado y evaluación del sistema se realiza en un entorno cloud híbrido, en el cual la extracción de datos se realizará desde la base de datos MySQL externa de Registel, que almacena la información bruta de la operación de Montebello. Las fases de limpieza, integración, modelado y evaluación se

implementan de la plataforma Amazon Web Services (AWS), aprovechando su estructura escalable y automatizable.

La metodología es un proceso estructurado y secuencial que abarca desde la obtención y depuración de los datos operativos hasta la validación del modelo predictivo final. Cada fase metodológica contribuye de forma complementaria al cumplimiento de los objetivos de investigación.

La primera fase garantiza la calidad y conveniencia de la información, la segunda define la arquitectura y flujos de procesamiento que alimentan el modelo, la tercera trata el tema del entrenamiento y comparación de los distintos modelos de aprendizaje automático y la cuarta consolida la evaluación y validación de los resultados en función de su aplicabilidad práctica.

Esta secuencia metodológica asegura la coherencia, trazabilidad y reproducibilidad del proceso investigativo, constituyendo una base sólida para la implementación de un sistema de apoyo a la toma de decisiones en la programación y despacho vehicular en la empresa Montebello.

A continuación, se muestra la Tabla 2, que resume las fases metodológicas y el diseño experimental del proyecto, indicando los objetivos, procedimientos, instrumentos y resultados esperados en cada fase.

Tabla 2. Fases metodológicas y diseño experimental.

Fase	Objetivo al que apunta	Procedimientos principales	Instrumentos y técnicas	Resultados esperados
Fase 1. Caracterización de variables operativas, espaciales y temporales	Caracterizar las variables operativas, espaciales y temporales de los registros históricos de transporte de la empresa Montebello, con el fin de identificar patrones y factores determinantes del comportamiento de la demanda de pasajeros.	- Realizar la extracción selectiva de datos relevantes desde la base de datos de origen. - Aplicar procesos de limpieza, validación y normalización de los registros, asegurando integridad, consistencia y cobertura de la información. - Organizar y almacenar los datos validados en un formato estructurado y optimizado para análisis posteriores. - Ejecutar un análisis exploratorio inicial para identificar correlaciones, tendencias y estacionalidades.	Base de datos transaccional de la empresa Montebello, herramientas de análisis de datos y entornos de procesamiento estructurado.	Conjunto de datos limpio, validado y estructurado, con variables operativas, espaciales y temporales relevantes para el modelado de la demanda de pasajeros.
Fase 2. Diseño de la arquitectura del sistema de predicción y flujo de procesamiento de datos	Diseñar e implementar el flujo de integración y procesamiento de datos que conecte la base de datos externa con el entorno analítico, garantizando la calidad, trazabilidad y disponibilidad de la información para el modelado predictivo.	- Definir la arquitectura general del sistema de integración de datos y del flujo de procesamiento. - Diseñar el modelo lógico de datos y los mecanismos de transformación, control de calidad y actualización. - Establecer los procesos automáticos o semiautomáticos ETL. - Documentar la estructura, los procesos y los criterios de calidad que garanticen la reproducibilidad del flujo.	Entornos de desarrollo para integración de datos, lenguajes de programación de propósito general y herramientas para documentación y control de versiones.	Flujo de procesamiento e integración de datos diseñado y documentado, que garantice la disponibilidad y calidad de la información para la fase de modelado predictivo.
Fase 3. Implementación y comparación de modelos de aprendizaje automático	Implementar, entrenar y comparar distintos modelos de aprendizaje automático con el propósito de estimar la demanda de pasajeros en diferentes horizontes de tiempo y escenarios operativos.	- Preparar los conjuntos de datos de entrenamiento, validación y prueba a partir de los registros limpios. - Entrenar diversos modelos predictivos bajo diferentes configuraciones y parámetros.	Entornos de análisis y modelado estadístico, bibliotecas de aprendizaje automático y herramientas de visualización de datos.	Modelo predictivo entrenado, validado y comparado frente a alternativas, con métricas documentadas que demuestren su eficacia para estimar la demanda de pasajeros.

		• Calcular métricas de error y desempeño para cada modelo. • Seleccionar el modelo que obtenga los mejores resultados según las métricas definidas.		
Fase 4. Evaluación y validación del modelo predictivo	Evaluar la precisión, estabilidad y aplicabilidad del modelo con mejor desempeño, con el de generar información analítica que apoye la toma de decisiones en la programación y despacho vehicular.	• Realizar la evaluación técnica y estadística del modelo seleccionado mediante métricas de precisión, error y consistencia temporal. • Validar la aplicabilidad del modelo en escenarios simulados o históricos de operación. • Generar reportes analíticos e indicadores de desempeño que permitan interpretar los resultados obtenidos. • Proponer ajustes o estrategias de mejora continua basadas en los hallazgos del proceso de validación.	Técnicas de evaluación estadística, métodos de simulación y herramientas de análisis visual y reportes automáticos.	Sistema predictivo evaluado y validado, con resultados analíticos que demuestran su precisión, aplicabilidad y potencial para apoyar la planificación operativa en la empresa Montebello.

Fuente: elaboración propia

6.1. Cronograma de actividades.

El siguiente cronograma describe la planificación del proyecto en fases y actividades que reflejan la secuencia lógica del proceso metodológico. Incluye las tareas críticas y aquellas que pueden ejecutarse en paralelo, distribuido en un periodo de ocho meses. En la tabla 3 se detalla en cronograma de actividades.

Tabla 3. Cronograma de actividades.

Fases	Actividad	M1	M2	M3	M4	M5	M6	M7	M8
1. Caracterización de variables operativas, espaciales y temporales	A1: Identificación y documentación de fuentes de datos								
	A2: Extracción selectiva desde la base de datos de Registel								
	A3: Limpieza, validación y depuración de registros								
	A4: Análisis exploratorio (EDA) y selección de variables								
2. Diseño de la arquitectura y flujo de procesamiento de datos	A5: Definición del modelo lógico y conceptual de datos								
	A6: Diseño del flujo de procesamiento e integración de datos (ETL)								
	A7: Pruebas de consistencia y documentación del flujo								
3. Implementación y comparación de modelos predictivos	A8: Preparación de datasets (train, validation y test)								
	A9: Entrenamiento de modelos base (SARIMA, RF y XGBoost)								
	A10: Entrenamiento de modelos avanzados (LSTM o híbridos)								
	A11: Evaluación comparativa y selección del mejor modelo								
4. Evaluación y validación del modelo predictivo	A12: Validación técnica y estadística del modelo								

	A13: Simulación de escenarios y análisis de sensibilidad								
	A14: Elaboración de reportes analíticos y tableros de resultados								
5. Redacción y cierre del trabajo de grado	A15: Integración de resultados y redacción del informe final								
	A16: Revisión metodológica, ajustes y sustentación								

Fuente: elaboración propia.

6.2. Resultados esperados.

A continuación, se muestra la tabla 4, en donde se presenta la relación de los resultados esperados, su descripción, las evidencias de logro y los productos derivados.

Tabla 4. Resultados esperados.

Resultado	Descripción	Evidencia de logro	Producto esperado
1. Dataset limpio y estructurado	Conjunto de datos depurado, validado y normalizado que integra variables operativas, espaciales y temporales provenientes de la base de datos de Registel.	Registros validados sin duplicados, consistencia en formatos y documentación del diccionario de datos.	Dataset final en formato estructurado (CSV/Parquet) y reporte técnico de limpieza y validación.
2. Flujo automatizado de procesamiento de datos (ETL)	Diseño e implementación de un flujo reproducible para la extracción, transformación y carga de datos hacia el entorno analítico, garantizando trazabilidad y control de calidad.	Scripts y diagramas de flujo documentados, registro de logs de ejecución y evidencias de control de versiones.	Script o pipeline ETL operativo con documentación técnica y guía de uso.
3. Modelo predictivo de demanda de pasajeros	Entrenamiento y validación de modelos de aprendizaje automático capaces de estimar la demanda en diferentes horizontes temporales con métricas de precisión adecuadas.	Métricas de desempeño (MAE, RMSE, MAPE) obtenidas en pruebas de validación y comparación de modelos.	Modelo de aprendizaje automático entrenado y validado con reporte de resultados experimentales.

4. Análisis de sensibilidad y simulación de escenarios	Evaluación de la estabilidad y robustez del modelo ante variaciones en las condiciones operativas y variables de entrada.	Gráficos comparativos, resultados de pruebas bajo escenarios simulados y análisis de impacto de variables.	Informe de análisis de sensibilidad y simulación de escenarios operativos.
5. Indicadores analíticos y tableros de visualización	Generación de reportes analíticos que integren información sobre la demanda, ocupación y frecuencia de despacho, facilitando la toma de decisiones.	Visualizaciones, KPIs e informes con interpretación de resultados y recomendaciones operativas.	Tableros analíticos o dashboards con indicadores clave de desempeño.
6. Documentación metodológica y guía de implementación	Sistematización del proceso metodológico desarrollado durante la investigación, desde la caracterización de datos hasta la validación del modelo.	Documento técnico con descripción del flujo metodológico, justificación de técnicas y conclusiones de validación.	Informe metodológico y guía de implementación interna que respalde la replicabilidad del proyecto.
7. Informe académico del trabajo de grado	Documento final de investigación que consolida la metodología, resultados experimentales, análisis comparativos y conclusiones del proyecto.	Informe aprobado por el comité académico y sustentación ante jurado.	Documento final de tesis de maestría validado institucionalmente.

Fuente: elaboración propia.

7. RECURSOS Y ASPECTOS ECONÓMICOS

El desarrollo del presente proyecto no requiere aportes económicos por parte de la Universidad Autónoma de Occidente, dado que los recursos humanos y tecnológicos provienen directamente de Registel S.A.S., en la cual el investigador se desempeña laboralmente. Registel facilita el acceso a su infraestructura tecnológica, bases de datos históricas y equipo de cómputo, los cuales constituyen aportes en especie para la ejecución del proyecto. A continuación, se muestra la tabla 5 con el detalle del presupuesto.

Tabla 5. Presupuesto.

Concepto	Descripción	UAO		EXTERNA (Registel)	
		Efectivo	Especie	Efectivo	Especie
1. Personal	Investigador principal (estudiante de maestría, responsable del desarrollo analítico y técnico del proyecto)	\$ 0	\$ 0	\$ 0	\$ 15.000.000
	Director de tesis	\$ 0	\$ 20.000.000	\$ 0	\$ 0
Subtotal Personal		\$ 0	\$ 20.000.000	\$ 0	\$ 15.000.000
2. Viáticos	Desplazamientos locales ocasionales para validaciones o reuniones con la empresa Montebello	\$ 0	\$ 0	\$ 1.500.000	\$ 0
Subtotal Viáticos		\$ 0	\$ 0	\$ 1.500.000	\$ 0
3. Materiales y servicios	Servicios en la nube (AWS: S3, SageMaker, Glue, almacenamiento y validación durante 8 meses)	\$ 0	\$ 0	\$ 1.800.000	\$ 0
	Software y librerías de código abierto (Python, Pandas, Scikit-learn, etc.)	\$ 0	\$ 0	\$ 0	\$ 0
	Papelería, impresión y suministros básicos de documentación	\$ 0	\$ 0	\$ 0	\$ 0
Subtotal Materiales y servicios		\$ 0	\$ 0	\$ 1.800.000	\$ 0
4. Equipos	Equipo de cómputo asignado como dotación laboral (uso personal del investigador)	\$ 0	\$ 0	\$ 0	\$ 4.000.000
	Acceso a servidores y base de datos corporativa de Registel (uso sin costo para investigación)	\$ 0	\$ 0	\$ 0	\$ 2.000.000
Subtotal Equipos		\$ 0	\$ 0	\$ 0	\$ 6.000.000
5. Imprevistos	Costos menores no previstos (copias, respaldos, conectividad, adaptadores)	\$ 0	\$ 0	\$ 500.000	\$ 0
Subtotal Imprevistos		\$ 0	\$ 0	\$ 500.000	\$ 0

6. Publicaciones y divulgación	Impresión y encuadernación del documento final de tesis	\$ 0	\$ 0	\$ 300.000	\$ 0
Subtotal Publicaciones		\$ 0	\$ 0	\$ 300.000	\$ 0
TOTAL GENERAL		\$ 0	\$ 20.000.000	\$ 4.100.000	\$ 21.000.000

Fuente: elaboración propia.

8. REFERENCIAS

Adjei Boateng, A., Adams, C. A., & Akowuah, E. K. (2023). Estimating passenger demand using machine learning models: A systematic review. *Proceedings of the African Conference on Civil and Environmental Engineering (ACC 2023)* (págs. 1-12). Accra, Ghana: EDP Sciences.

Box, G. E., & Jenkins, G. M. (2015). *Time Series Analysis: Forecasting and Control*. John Wiley & Sons.

Ceder, A. (2016). *Public transit planning and operation: Modeling, practice and behavior*. Boca Raton, FL: CRC Press.

Chen, X., Liu, A., & Zhu, H. (2020). Bus headway regularity analysis and control in urban public transport. *Transportation Research Record*, 123–134.

Chuwang, D. D., & Chen, W. (2022). Forecasting daily and weekly passenger demand for urban rail transit stations based on a time series model approach. *Forecasting*, 4(4), 904-924. doi:10.3390/forecast4040049

Han, Y., Wang, C., Ren, Y., Wang, S., Zheng, H., & Cheng, G. (2019). Short-term prediction of bus passenger flow based on a hybrid optimized LSTM network. *ISPRS International Journal of Geo-Information*, 24.

He, Y., Li, L., Zhu, X., & Tsui, K. L. (2022). Multi-graph convolutional-recurrent neural network (MGC-RNN) for short-term forecasting of transit passenger

- flow. *IEEE Transactions on Intelligent Transportation Systems*, 23(5), 5124-5136. doi:10.1109/TITS.2021.3057554
- Hoppe, S., Müller, J., & Schäfer, T. (2023). Integrating short-term passenger forecasts with real-time occupancy data for adaptive public transport operations. *Transportation Research Part C: Emerging Technologies*, 149, 104085. doi:10.1016/j.trc.2023.104085
- Litman, T. (2022). *Evaluating public transportation health benefits (2nd ed.)*. Victoria, BC: Victoria Transport Policy Institute (VTPI).
- Luo, D., Zaho, Q., Ke, Q., You, X., Liu, L., Zhang, D., . . . Zuo, D. (2021). A multi-task deep learning model for service-level passenger flow prediction in bus transit systems. *IEEE Transactions on Intelligent Transportation Systems*, 22(12), 7550-7563. doi:10.1109/TITS.2020.3008983
- Martínez, J., Pérez, L. F., & Rojas, C. A. (2024). Tactical planning of bus dispatch operations using scenario analysis and machine learning approaches: A case study in Bogotá, Colombia. *Transportation and Development Journal of ASCE*, 150.
- Matseliukh, Y., Lytvyn, V., & Bublyk, M. (2025). Development of a neural network for forecasting passenger flows in smart city public electric transport. *Technology Audit and Production Reserves*, 1-9.
- Rocco, E. (2024). Machine learning approaches for passenger demand forecasting: A comprehensive review. *Journal of Transportation and Artificial Intelligence*, 45-67.
- Rodríguez-Valencia, A. (2023). La transformación del sistema de transporte público en Bogotá: Evolución, retos y aprendizajes del SITP. *Revista de Transporte y Territorio*, 15-38.

- Turban, E., Sharda, R., & Delen, D. (2021). *Decision support and business intelligence systems*. London: Pearson.
- Turner, M., & Wright, D. (2020). *Public transport service planning and operation: Modeling, performance and evaluation*. London, United Kingdom: Routledge (Taylor & Francis Group).
- Wang, J., & Shalaby, A. (2024). DST-TransitNet: A dynamic spatio-temporal deep learning model for scalable and efficient network-wide prediction of station-level transit ridership. *IEEE Open Journal of Intelligent Transportation Systems*, 16.
- Yazıcıoğlu, O., & Erdem, A. (2025). Multivariate LSTM models for passenger demand forecasting in mixed public transport systems. *IEEE Access*, 12.
- Yu, B., Yin, H., & Zhu, Z. (2018). Spatio-temporal graph convolutional networks: A deep learning framework for traffic forecasting. *Proceedings of the 27th International Joint Conference on Artificial Intelligence* (págs. 3634–3640). Estocolmo, Suecia: IJCAI Organization.
- Zhang, G.-B. (2020). Time series forecasting using a hybrid ARIMA and neural network model: An integrated approach. *Neurocomputing*, 50, 159-175.
doi:10.1016/S0925-2312(01)00702-0
- Zhao, Z., Wang, P., & Li, J. (2021). Passenger demand forecasting in urban rail transit based on improved hybrid models. *Journal of Advanced Transportation*, 1-12.
- Zou, Z., & Ma, H. (2023). Research on metro transportation flow prediction based on the STL-GRU combined model. *Journal of Transportation Systems and Information Technology*, 45-58.